Universidade Federal de Santa Catarina
Centro Tecnológico
Departamento de Engenharia Elétrica e Eletrônica

PROPOSTA DE PROJETO

PROCESSAMENTO DE IMAGENS — PROJETO NÍVEL I

Reconhecimento e Contagem Automática do Movimento de Sentar e Levantar com Estimação de Pose e Aprendizado Supervisionado

Luiz Felipe Steinck Matrícula: 19100418
Luis Felipe Candido Sola Matrícula: 22250296

Professor responsável
Prof. Joceli Mayer

Florianópolis
2026

1. Título e equipe

Título: Reconhecimento e Contagem Automática do Movimento de Sentar e Levantar com Estimação de Pose e Aprendizado Supervisionado
Escopo em uma frase: desenvolver e avaliar um protótipo em português que reconheça as fases do movimento de sentar e levantar, conte somente ciclos completos e registre resultados mensuráveis em tempo real.

O trabalho será desenvolvido em dupla. A divisão abaixo estabelece responsáveis principais, sem impedir revisão cruzada e colaboração nas decisões técnicas.

Integrante	Matrícula	Responsabilidades principais
Luiz Felipe Steinck	19100418	Integração OpenCV–MediaPipe, método geométrico de referência, interface em português, execução em tempo real e registro em CSV.
Luis Felipe Candido Sola	22250296	Protocolo de aquisição e rotulagem, preparação dos atributos, treinamento supervisionado, métricas e análise dos experimentos.
Ambos	—	Definição metodológica, integração final, testes, interpretação dos resultados, redação do relatório e apresentação.

2. Introdução

O movimento de sentar e levantar está presente em atividades cotidianas e envolve coordenação entre tronco e membros inferiores. Sua execução apresenta variações de velocidade, amplitude, proporção corporal, enquadramento e iluminação. Essas condições fazem do movimento um caso adequado para estudar processamento de vídeo, extração de características, classificação de padrões e análise temporal. A literatura também reconhece o movimento como uma tarefa funcional relevante, embora sua interpretação clínica dependa de protocolo e supervisão profissional [6].

A estimação de pose permite representar o corpo por pontos anatômicos em vez de processar diretamente todos os pixels. O MediaPipe Pose Landmarker fornece 33 marcos corporais e foi projetado para aplicações em tempo real, inclusive atividades físicas [1, 4]. A partir desses marcos, é possível calcular ângulos, posições normalizadas e variações ao longo do tempo.

O projeto parte de um protótipo já funcional, capaz de acessar a webcam, estimar a pose, calcular ângulos, calibrar as posturas sentada e em pé, reconhecer fases por regras geométricas, contar ciclos completos e gravar dados em CSV. A proposta amplia essa base com um classificador supervisionado, um protocolo de avaliação quantitativa e uma interface visual mais clara em português. O repositório de Guarnizo [5] será usado apenas como referência prática de organização de uma aplicação de análise de exercícios; o código, os experimentos e a avaliação deste trabalho serão próprios.

Delimitação: trata-se de um protótipo acadêmico de visão computacional. O sistema não fará diagnóstico, prescrição de exercício, avaliação de dor ou validação clínica de postura.

3. Objetivos

3.1 Objetivo geral

Desenvolver e avaliar um sistema de visão computacional que reconheça as fases do movimento de sentar e levantar e contabilize repetições completas a partir de vídeo de uma webcam comum.

3.2 Objetivos específicos

- adquirir vídeo e estimar, em tempo real, os marcos de ombro, quadril, joelho e tornozelo;
- extrair atributos geométricos e temporais independentes da resolução da imagem;
- manter um método geométrico calibrável como referência de comparação;
- treinar e comparar classificadores supervisionados para as classes `SENTADO`, `TRANSIÇÃO` e `EM PÉ`;
- usar uma máquina de estados para distinguir levantar de sentar e contar somente o ciclo completo `sentado → em pé → sentado`;
- melhorar a interface em português, com informações objetivas sobre enquadramento, fase, repetição e perda de rastreamento;
- medir a qualidade da classificação, o erro de contagem e o desempenho computacional.

3.3 Metas e resultados esperados

As metas técnicas são processar ao menos 15 quadros por segundo em computador convencional; obter F1 macro igual ou superior a 0,85 para as três fases em sessões controladas; e alcançar erro absoluto médio de, no máximo, uma repetição a cada sequência de dez movimentos. Esses valores são metas de engenharia, não resultados antecipados. Caso não sejam atingidos, os erros serão documentados e analisados.

Como resultados, espera-se entregar o programa executável, um conjunto interno de vídeos e rótulos, arquivos de configuração, registros CSV, gráficos de avaliação, demonstração ao vivo e relatório com comparação entre os métodos.

4. Métodos

4.1 Fluxo proposto

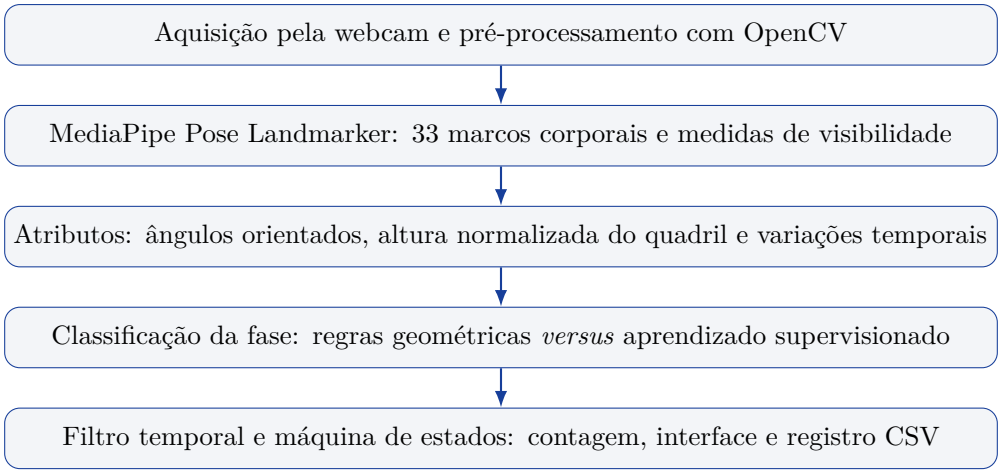


Figura 1: Fluxo de processamento e avaliação do sistema proposto.

Cada quadro será convertido de BGR para RGB com OpenCV [2] e enviado ao estimador de pose. O lado corporal com maior visibilidade será selecionado para reduzir falhas por oclusão. Para preservar a orientação geométrica no plano da imagem, o ângulo associado a três pontos A, B e C, com vértice em B, será obtido a partir dos vetores $\mathbf{u} = A - B$ e $\mathbf{v} = C - B$ por

$$\theta_s = \operatorname{atan2}(u_x v_y - u_y v_x,\ \mathbf{u} \cdot \mathbf{v}), \qquad -\pi < \theta_s \leq \pi. \tag{1}$$

A magnitude $|\theta_s|$ será usada nos atributos de postura, enquanto a série orientada será normalizada entre os lados corporais e desenrolada no tempo quando necessário para preservar a continuidade angular. Dessa forma, o sinal e a evolução temporal podem auxiliar na distinção do sentido do movimento sem reduzir o ângulo ao intervalo $[0, \pi]$. Como a medição é bidimensional, ela representa apenas a projeção do movimento no plano da imagem e não será interpretada como medida clínica de hiperextensão ou de rotação tridimensional.

Serão utilizados os ângulos do joelho e do quadril, a inclinação do tronco, a altura do quadril normalizada por uma medida corporal e as variações dessas grandezas entre quadros. A normalização reduz a influência da distância entre a pessoa e a câmera. Uma média móvel exponencial (EMA) suavizará oscilações rápidas:

$$\widehat{x}_k = \alpha x_k + (1 - \alpha)\widehat{x}_{k-1}, \qquad 0 < \alpha \leq 1. \tag{2}$$

Por ser um filtro causal, a EMA introduz atraso temporal: valores menores de α produzem maior suavização, porém deslocam a resposta em relação ao movimento real. Portanto, α não será fixado apenas por inspeção visual. Ele será selecionado nas sessões de treinamento/validação, em conjunto com a janela de estabilidade da máquina de estados, considerando F1 macro, erro de contagem, falsas transições e latência entre a mudança observada nos atributos brutos e a mudança de estado confirmada. As sessões de teste permanecerão fora dessa escolha para evitar ajuste ao conjunto de avaliação.

4.2 Dois métodos de classificação

Método A — referência geométrica. Após uma calibração individual nas posturas sentada e em pé, regras sobre ângulos e altura do quadril fornecerão uma referência interpretável. Uma fase só será confirmada após permanecer estável por vários quadros, reduzindo mudanças causadas por ruído.

Método B — classificação supervisionada. Os mesmos atributos alimentarão modelos do Scikit-learn [7]. Serão avaliados Regressão Logística e Floresta Aleatória [3]. Pré-processamento e modelo serão reunidos em um *pipeline*, para que a padronização seja aprendida somente com o conjunto de treinamento.

O classificador reconhecerá três fases estáticas. A máquina de estados observará a sequência temporal para identificar `LEVANTANDO` e `SENTANDO`. A contagem só avançará após a sequência completa; tentativas sem atingir a fase em pé, mudanças isoladas e perdas prolongadas de rastreamento serão rejeitadas.

4.3 Aquisição, rotulagem e divisão dos dados

Serão gravadas 12 sessões controladas, seis por integrante, com 8 a 12 repetições por sessão. Haverá variação moderada de iluminação, roupa e distância, porém a geometria de aquisição será controlada: a câmera permanecerá fixa, aproximadamente à altura do quadril, com o plano do sensor paralelo ao plano sagital do movimento e o eixo óptico aproximadamente perpendicular a esse plano. A pessoa será posicionada lateralmente, próxima ao centro da imagem e com o corpo inteiro visível. Marcas no piso serão usadas para repetir a orientação e a distância entre sessões. Essa restrição reduz erros de perspectiva e é necessária porque os ângulos extraídos são projeções bidimensionais. Os vídeos serão rotulados por intervalos nas classes `SENTADO`, `TRANSIÇÃO` e `EM PÉ`. Quadros pouco visíveis serão inválidos, e parte das sequências incluirá movimentos incompletos.

Treino e teste serão separados por sessão, não por quadros aleatórios. Assim, quadros consecutivos da mesma gravação não aparecerão nos dois conjuntos, o que reduziria artificialmente o erro. A seleção do modelo usará validação cruzada em grupos. Como haverá apenas dois participantes, os resultados demonstrarão funcionamento controlado, sem pretensão de generalização para a população.

4.4 Avaliação

Os métodos A e B serão comparados nas mesmas sessões. Para as fases serão calculados acurácia balanceada, precisão, revocação, F1 macro e matriz de confusão. Para a tarefa final serão medidos contagem real e estimada, erro absoluto, falsas contagens, rejeição de tentativas incompletas, perdas de rastreamento e quadros por segundo. Os erros serão analisados por iluminação, enquadramento e oclusão.

5. Materiais e ferramentas

O modelo de pose pré-treinado e o pequeno conjunto de atributos dispensam GPU dedicada. A arquitetura separará captura, geometria, classificação, lógica temporal, interface e exportação. Os testes automáticos de ângulos, fases e contagem serão preservados e ampliados; uma CNN sobre imagens completas ficará fora do escopo.

Os vídeos serão produzidos pela equipe e armazenados localmente durante o desenvolvimento. A demonstração usará somente imagens autorizadas; eventual participante adicional deverá concordar com a gravação. Não serão coletados nomes, condições médicas ou dados clínicos.

Recurso	Finalidade	Situação
Python 3.11 e ambiente virtual	Execução isolada e reprodutível do projeto	**Disponível/testado**
OpenCV	Captura da webcam, conversão de cor, desenho e interface de vídeo	**Disponível/testado**
MediaPipe Pose Landmarker	Estimação dos 33 marcos corporais	**Disponível/testado**
Scikit-learn	*Pipelines*, validação, classificadores e métricas	**Disponível/testado**
NumPy e Pandas	Cálculo numérico e armazenamento dos resultados	**Disponível/testado**
Webcam de notebook/USB	Aquisição dos vídeos em plano lateral	**Disponível/testado**
Protótipo em português	Calibração, fases, contagem, mensagens e CSV	**Disponível/testado**
Vídeos e rótulos do experimento	Treinamento e teste por sessão	**Planejado**
Interface revisada	Organização visual, controles e apresentação dos resultados	**Em desenvolvimento**

Tabela 1: Recursos previstos e estágio atual.

6. Cronograma

Período	Etapa e entrega verificável	Responsável principal
18 a 25/09	Consolidação do escopo, proposta e identidade visual; submissão do PDF	Ambos
26/09 a 09/10	Protocolo de gravação, teste-piloto e definição do guia de rotulagem	Luis Sola; revisão de Luiz Steinck
10 a 23/10	Aquisição e rotulagem das 12 sessões; exportação dos atributos	Ambos
24/10 a 06/11	Treinamento, validação por grupos e comparação dos classificadores	Luis Sola
07 a 20/11	Integração do modelo, revisão da interface e testes de falha	Luiz Steinck
21 a 30/11	Experimentos finais, gráficos, relatório, demonstração e apresentação	Ambos

Tabela 2: Etapas previstas para o desenvolvimento.

Conclusão e controle de riscos: o projeto estará completo com demonstração reproduzível, comparação quantitativa, análise de erros e instruções de execução. Oclusões, rastreamento instável e poucos exemplos serão tratados com controle da geometria lateral da câmera, verificação de visibilidade, suavização temporal com latência explicitamente avaliada, divisão por sessão e coleta em condições variadas.

Referências

[1] Valentin Bazarevsky, Ivan Grishchenko, Karthik Raveendran, Tyler Zhu, Fan Zhang, and Matthias Grundmann. BlazePose: On-device real-time body pose tracking. *arXiv preprint arXiv:2006.10204*, 2020. doi: 10.48550/arXiv.2006.10204. URL https://arxiv.org/abs/2006.10204.

[2] Gary Bradski. The opencv library. *Dr. Dobb's Journal of Software Tools*, 2000. URL https://opencv.org/.

[3] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001. doi: 10.1023/A:1010933404324.

[4] Google. Pose landmarker: Python guide. MediaPipe Solutions Documentation, 2026. URL https://developers.google.com/edge/mediapipe/solutions/vision/pose_landmarker/python. Acesso em: 17 set. 2026.

[5] Daniel Guarnizo. Pose estimation for fitness exercise analysis. Repositório de código no GitHub, s.d. URL https://github.com/DanielGuarnizo/Pose-Estimation-for-Fitness-Exercise-Analysis. Acesso em: 17 set. 2026.

[6] Wim G. M. Janssen, Hans B. J. Bussmann, and Henk J. Stam. Determinants of the sit-to-stand movement: A review. *Physical Therapy*, 82(9):866–879, 2002. doi: 10.1093/ptj/82.9.866.

[7] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12(85):2825–2830, 2011. URL https://jmlr.org/papers/v12/pedregosa11a.html.